PropSight — Independently Researched Solution Proposal

Base: diagnóstico em `PropSight_critical_assessment.md` (9 out 2026) e pesquisa externa citada ali e aqui. Este documento não repete o diagnóstico; ele propõe. Quando uma afirmação depende de algo ainda não validado, está marcada **[HIPÓTESE]**. Quando é capacidade já existente em ferramenta ou fonte identificada, está marcada **[EXISTE]**.

Nome de trabalho da primeira versão: *PropSight Check* ("verifique antes de visitar").

---

1. Conceito de produto recomendado

O que é. Uma verificação sob demanda de um único imóvel anunciado em Recife, iniciada pela URL do anúncio, que entrega em cerca de um minuto um *dossiê de evidências* com quatro blocos fixos: (1) qual edifício é este e com que confiança; (2) o que registros oficiais e a geografia dizem sobre ele e sobre a rua; (3) o que o anúncio declara e o que nele é inconsistente ou incompleto; (4) o que ainda não se sabe e exatamente como descobrir, incluindo uma lista de documentos a pedir e perguntas a fazer. Se o usuário enviar documentos do condomínio depois (atas, balancetes, convenção), o dossiê é atualizado com uma leitura referenciada por página.

Para quem. Pessoa física em Recife que já encontrou um anúncio e está decidindo se visita, se propõe ou se assina. Primeiro recorte: locatários e compradores de apartamentos em edifícios (não casas), porque é onde a identidade do edifício importa, onde os documentos condominiais existem e onde Recife tem risco documentado (prédios-caixão, setores de risco, alagamento).

O que não é. Não é buscador, não é estimador de preço, não é chatbot, não é inspetor, não é comparador de bairros. Não emite score. A decisão de recorte vem da aplicação da seção 28 do manifesto ao universo da seção 6 (ver seção 10 deste documento).

Uma frase. PropSight Check transforma a URL de um anúncio em um registro verificável do que se sabe, do que o anúncio declara e do que ainda precisa ser confirmado sobre aquele edifício, antes que a pessoa gaste uma visita ou assine um contrato.

---

2. Problema central e proposta de valor

A decisão que melhora: "vale a pena gastar uma visita (ou uma proposta) neste imóvel, e o que eu preciso perguntar e pedir antes?"

Por que essa decisão e não "qual imóvel escolher": escolher entre imóveis exige cobertura de inventário e preferências calibradas, que o manifesto admite não ter (5.3, 5.4). Verificar um imóvel exige apenas o anúncio, fontes oficiais e, opcionalmente, documentos. É a menor decisão que o produto pode melhorar sem inventário e sem scraping longitudinal.

Vantagem que deve entregar, mensurável:

1. **Tempo:** reduzir de horas (abrir portal de dados, baixar GeoJSON do SGB, procurar lote, ler atas) para um minuto o levantamento do que é público sobre o edifício.
2. **Descoberta:** em pelo menos metade dos anúncios, mostrar um fato verificável que o usuário não encontraria sozinho e que muda uma pergunta, uma visita ou uma condição de proposta **[HIPÓTESE, testada em E2]**.
3. **Proteção:** zero afirmações falsas; cada claim com fonte, data e escala. É o que distingue o produto de um LLM genérico, que no uso real por compradores produz dados inventados sobre anúncios locais (Neuhaus RE).
4. **Ação:** uma lista de documentos a pedir e perguntas a fazer gerada a partir do que ficou desconhecido, não de um template.

Posicionamento contra os substitutos (síntese do benchmark):

- Portais (QuintoAndar, ZAP/OLX) otimizam descoberta e contato; PropSight Check atua depois da descoberta e antes do contato.
- LLMs genéricos sintetizam; PropSight Check resolve identidade, consulta fontes oficiais brasileiras e registra proveniência.
- Sprift (UK) é o modelo de produto mais próximo, mas depende de dados públicos ricos por UPRN; PropSight Check constrói o equivalente brasileiro para um município por vez, começando pela camada de edifício.

---

3. Inovação proposta

A inovação está em três mecanismos concretos, nenhum deles "IA" no sentido de modelo preditivo.

3.1 Resolvedor de edifício para anúncios brasileiros (mecanismo central)

Problema: o anúncio diz "Rua X, Boa Viagem, edifício Y, 3 quartos, 95 m²" e raramente o número. Nenhuma fonte oficial responde por "edifício Y".

Mecanismo:

1. Extração estruturada do anúncio (logradouro, bairro, nome do edifício, andar, área, fotos de fachada se houver). **[EXISTE]** LLM com saída estruturada + parser de página.
2. Geração de candidatos por interseção de quatro fontes: (a) edificações e lotes do Recife em GeoJSON (Dados Abertos Recife) filtrados pelo logradouro; (b) CNEFE 2022 do IBGE, que traz coordenadas por endereço e, para edifícios, espécies de endereço por unidade (IBGE); (c) OpenStreetMap (`building`, `name`, `addr:*`); (d) uma tabela própria e crescente de nomes de edifício → lote, alimentada por confirmações de usuários.
3. Pontuação probabilística dos candidatos com Splink **[EXISTE]** (GitHub) sobre campos pouco correlacionados: nome do edifício (fuzzy), logradouro, número quando houver, número de pavimentos (área construída / área do lote nos dados municipais vs. andar declarado), ano aproximado, presença de atributos (piscina, vagas) em imagens aéreas quando disponíveis.
4. Decisão em três faixas: confiança alta (associa registros do edifício e do lote); média (mostra 2 ou 3 candidatos no mapa e pede um toque); baixa (relatório restrito à rua e ao bairro, com o edifício marcado como não resolvido).
5. Cada confirmação do usuário vira um rótulo que realimenta a tabela (d). **[HIPÓTESE]** Este é o único ativo de dados que se acumula desde o primeiro usuário e que nenhum concorrente tem para Recife; equivale, em pequena escala, ao papel do UPRN no Sprift.

O que é novo: não a técnica, mas a aplicação a anúncios com endereço incompleto usando dados municipais e censitários brasileiros, com a confirmação humana desenhada como parte do fluxo e não como falha.

3.2 Ledger de evidência com linguagem calibrada por construção

Cada cartão do dossiê é um registro com: claim, categoria da escala da seção 11 do manifesto (mais uma sétima categoria, "declarado pelo anunciante"), fonte com link, data de referência, data de coleta, escala espacial (unidade / edifício / lote / rua / microárea / bairro), método, limitação principal e ação sugerida. O texto exibido é gerado a partir desse registro por templates por categoria, não livremente por LLM. A lista de afirmações proibidas (11.3 do manifesto) vira teste automatizado sobre o texto final. **[EXISTE]** como padrão de engenharia; a novidade é aplicá-lo como restrição de produto e não como documentação.

3.3 Desconhecidos como saída de primeira classe

O dossiê computa explicitamente o conjunto de perguntas relevantes para aquele tipo de imóvel (matriz: aluguel/compra × apartamento × Recife) e marca cada uma como respondida (com evidência), parcialmente respondida, ou desconhecida. As desconhecidas geram automaticamente: documento a pedir, pergunta ao corretor ou síndico, item de visita, ou "requer profissional". **[HIPÓTESE]** que isso aumenta confiança

e ação (testado em E5). Nenhum benchmark identificado faz isso; Zillow/First Street mostravam scores, Sprift mostra dados, Homie dá veredito.

3.4 Leitor documental referenciado (módulo opcional de alto valor)

Para atas, balancetes e convenção enviados pelo usuário: extração de eventos (obra, cota extraordinária, inadimplência, litígio, manutenção de elevador/fachada/bombas, interdição, seguro) com página, trecho, data e status aparente. **[EXISTE]** como capacidade de LLM com document parsing. **[INFERÊNCIA]** As ferramentas de IA condominial no Brasil servem síndicos e administradoras (SíndicoNet), não o comprador ou locatário que recebe um PDF de 80 páginas. É o módulo com melhor razão valor/risco porque usa dados do próprio usuário (sem scraping) e porque a saída é "trecho e página", verificável em segundos.

O que deliberadamente não é inovação aqui

- Isócronas e declividade: integrar openrouteservice ou OSMnx **[EXISTE]**.
- Exposição solar: integrar API Sunscore da Shadowmap ou calcular sombreamento geométrico com alturas de edificações **[EXISTE]** (Shadowmap API).
- Deduplicação: Splink **[EXISTE]**.
- Sinais compostos (calor, ruído, acesso em chuva modelado): fora da V1, programa de pesquisa.

---

4. Jornada de primeiro uso, de ponta a ponta

Cenário: locatário em Recife, celular, primeira vez, cola a URL de um apartamento em Boa Viagem.

Passo	O que o usuário faz	O que o sistema faz (bastidores)	O que o usuário vê	Valor desta interação	Tempo
0	Abre o app/site	Nada além de carregar a tela	Um campo: "Cole o link do anúncio" e, abaixo, "ou digite o endereço". Nada mais. Sem cadastro.	Zero fricção; a promessa é explícita	0 s
1	Cola a URL	Busca a página do anúncio no momento (leitura única,	"Lendo o anúncio…" com os campos aparecendo	Prova imediata de que o sistema entendeu; o	5 a 10 s

Passo	O que o usuário faz	O que o sistema faz (bastidores)	O que o usuário vê	Valor desta interação	Tempo
		sem armazenar HTML além do necessário); extrai campos estruturados; registra cada campo como "declarado pelo anunciante"	conforme extraídos (preço, condomínio, IPTU, área, quartos, andar, edifício, rua, bairro)	usuário pode corrigir um campo errado tocando nele	
2	(Só se necessário) Toca no edifício correto entre 2 ou 3 pinos	Resolvedor gera candidatos (seção 3.1); se confiança alta, pula este passo	Mapa com pinos candidatos, nome e foto de fachada quando disponível; "Qual é o prédio? (não temos certeza)"	Única entrada obrigatória além da URL; cada confirmação melhora o sistema	5 s
3	Aguarda	Enriquecimento paralelo: interseção do lote com setores de risco (SGB, Defesa Civil), ocorrências de Defesa Civil na microárea, lote e edificação cadastrados, rede de pedestres e declividade para 5 categorias de POI, exposição solar da fachada, consistência interna do anúncio, custo mensal total.	Tela de carregamento com os quatro blocos aparecendo progressivamente	Primeiro resultado útil em menos de um minuto **[HIPÓTESE: testar]**	20 a 40 s

Passo	O que o usuário faz	O que o sistema faz (bastidores)	O que o usuário vê	Valor desta interação	Tempo
		Tudo escrito no ledger			
4	Lê o bloco 1: **Identidade**		"Edifício Y, Rua X nº N, lote 12345. Confiança: alta (nome e rua confirmados; fachada compatível). Edificação cadastrada: 12 pavimentos, área construída Z m²."	Confiança de que tudo abaixo é sobre o prédio certo	
5	Lê o bloco 2: **O que os registros oficiais dizem**	Cada cartão com categoria, fonte, data e escala	Ex.: "Registro oficial: o lote não intersecta setor de risco alto ou muito alto do SGB (setorização 2021). Isso vale para o lote; não cobre a garagem subterrânea nem a rua em chuva intensa." / "Registro oficial: 3 ocorrências de Defesa Civil num raio de 150 m em 2024-2025 (alagamento de via). Escala: rua, não o edifício." / "Observação direta (geometria): a rota a pé até o metrô mais próximo tem 1,4 km pela rede de calçadas, contra	A descoberta que a pessoa não faria sozinha, com os limites explícitos	

Passo	O que o usuário faz	O que o sistema faz (bastidores)	O que o usuário vê	Valor desta interação	Tempo
			650 m em linha reta, com 22 m de subida."		
6	Lê o bloco 3: **O que o anúncio declara e o que não bate**	Regras de consistência	Ex.: "Declarado: 95 m². A área cadastrada média por unidade neste edifício é 78 m². Pode ser área total vs. privativa. Confirme a área privativa na matrícula." / "Custo mensal total declarado: R$ 2.900 + R$ 780 + R$ 95 = R$ 3.775. IPTU informado; condomínio informado; seguro-fiança não informado."	Evita surpresa financeira e pergunta objetiva	
7	Lê o bloco 4: **O que ainda não sabemos e como descobrir**	Matriz de perguntas × evidências	"Não sabemos: situação financeira do condomínio; obras aprovadas; histórico de infiltração; isolamento acústico. Peça ao corretor: últimas 12 atas, balancete, convenção. Pergunte: há cota extraordinária aprovada? Na visita: olhe o teto do último andar e	Transforma incerteza em lista de ações; é a parte compartilhável	

Passo	O que o usuário faz	O que o sistema faz (bastidores)	O que o usuário vê	Valor desta interação	Tempo
			a garagem após chuva. Requer profissional: qualquer dúvida estrutural."		
8	Toca em "Enviar documentos" (opcional, depois)	Leitor documental (3.4)	Eventos com página e trecho; bloco 4 atualizado (desconhecidos viram respondidos)	Segunda sessão com valor crescente; é o gancho de retenção	min
9	Toca em "Compartilhar dossiê"	Gera link ou PDF com ledger	Documento legível por terceiros (parceiro, família, corretor)	Distribuição orgânica; abre caminho para o canal corretor	s
10	(Opcional, nunca antes do passo 7) "Quer que eu considere sua rotina?"	Pede 1 a 3 pontos (trabalho, escola, academia)	Bloco 2 ganha rotas reais para esses pontos	Personalização só depois do valor, só com dado que muda a resposta	

Decisões de desenho embutidas:

- Nenhuma pergunta de preferência antes do resultado. Personalização é um refinamento pós-valor.
- A única interação obrigatória além da URL é a confirmação do edifício, e só quando necessária.
- Os quatro blocos têm ordem fixa. Identidade primeiro, porque é a condição de validade; desconhecidos por último, porque são a ação.
- Nunca um número-resumo. O "resumo" é a contagem de cartões por tipo (ex.: 2 registros oficiais, 1 inconsistência, 5 desconhecidos).

---

5. Desenho de entrada e interação

Categoria	Item	Por quê
Automático	Extração de campos do anúncio; resolução do edifício quando confiança alta; todos os registros oficiais; geometria de rotas; exposição solar; custo mensal total; checklist e perguntas	Tudo que depende só da URL e de fontes públicas
Explicitamente pedido (obrigatório condicional)	Confirmação do edifício entre candidatos	Única entrada que muda a validade de tudo; não pode ser inferida com segurança
Opcional, oferecido no fim	Pontos de rotina (até 3); orçamento máximo; "preciso de acessibilidade" e outras restrições duras	Mudam cartões específicos; nunca condicionam o primeiro resultado
Diferido (sessão 2)	Documentos do condomínio; matrícula (CNM); resposta do corretor às perguntas	O usuário raramente os tem no primeiro contato; o produto diz como obtê-los
Nunca na V1	Localização em tempo real; áudio; fotos de visita; medição LiDAR; preferências por escolhas pareadas; observação de comportamento	Custo de privacidade e de validação acima do valor demonstrável (manifesto 12.2, 13.2, 17.4)

Sobre voz, fotos e localização: nenhuma justifica a fricção no primeiro uso. As fotos relevantes já estão no anúncio (usadas apenas para identificação de fachada e consistência, nunca para "inspeção"). Localização do usuário só teria valor para rotas, e para isso basta digitar "meu trabalho é na Av. Z", o que é menos invasivo.

---

6. Modelo técnico da solução (entrada → processo → saída)

```
ENTRADA
  URL do anúncio (ou endereço)
      │
      ▼
[1] EXTRAÇÃO
  fetch único da página → texto + imagens
  LLM com schema estruturado → campos tipados, cada um com "declarado
pelo anunciante"
```

```
  sem armazenar o HTML além da sessão (reduz exposição a termos de uso)
      │
      ▼
[2] RESOLUÇÃO DE IDENTIDADE
  geração de candidatos (lotes/edificações Recife + CNEFE + OSM + tabela
própria)
  pontuação Splink → confiança
  alta → segue | média → pedir confirmação | baixa → modo "rua/bairro"
  grava: listing_id, building_id, parcel_id, confidence,
evidence_of_match
      │
      ▼
[3] ENRIQUECIMENTO POR FONTES OFICIAIS E GEOMETRIA (paralelo, cada
chamada com contrato de fonte)
  a. risco: interseção lote × setores SGB; ocorrências Defesa Civil por
raio e data
  b. cadastro: edificação (pavimentos, área construída), lote, zona
  c. mobilidade: openrouteservice/OSMnx: distância de rede, declividade,
travessias para 5 POIs padrão
  d. sol: Sunscore (Shadowmap API) ou cálculo geométrico próprio com
alturas
  e. anúncio: regras de consistência (área vs. cadastro, custo total,
campos ausentes)
      │
      ▼
[4] LEDGER DE EVIDÊNCIA
  cada resultado vira um registro: claim, categoria, fonte, data_ref,
data_coleta,
  escala, método, limitação, ação; versão do método
      │
      ▼
[5] MATRIZ DE PERGUNTAS
  perguntas relevantes (tipo de operação × tipo de imóvel) × evidências
do ledger
  → respondida / parcial / desconhecida
  desconhecida → documento a pedir | pergunta | item de visita |
profissional
      │
      ▼
[6] APRESENTAÇÃO
  templates por categoria da escala de confiança
  testes de wording proibido (11.3) antes de renderizar
  quatro blocos fixos; camada 2 (evidência) por toque; camada 3 (método)
por toque
      │
      ▼
SAÍDA
  dossiê interativo + link/PDF compartilhável + ledger exportável
      │
      ▼ (sessão 2, opcional)
[7] DOCUMENTOS DO USUÁRIO
```

```
  upload cifrado → parsing → extração de eventos com
página/trecho/status → ledger → matriz
```

Persistência: PostgreSQL/PostGIS para entidades e ledger (coerente com 9.5 do manifesto); DuckDB para auditorias de fontes; armazenamento de objetos cifrado para documentos com retenção definida; sem data lake de anúncios na V1.

Modos de operação: apenas sob demanda. O modo batch longitudinal (snapshots de portal) fica fora até existir fonte lícita; a arquitetura permite acoplá-lo depois como fonte adicional de cartões (histórico de preço, duplicatas).

Custo por análise [HIPÓTESE]: poucas chamadas de LLM (extração, parsing documental), consultas espaciais locais, 1 chamada de API de sol se externa; da ordem de centavos a poucos reais por dossiê. Deve ser medido (23.4 do manifesto).

---

7. Estratégia de dados e tecnologia

7.1 Fontes da V1 (todas lícitas sem negociação)

Fonte	Uso	Licença / acesso	Limitação conhecida	Status
Página do anúncio colada pelo usuário	Extração de campos	Leitura única a pedido do usuário; não armazenar além da sessão; revisar termos do portal (ver riscos)	Campos ausentes; endereço incompleto	A validar juridicamer
Dados Abertos Recife: Edificações-Lotes, quadras, bairros	Candidatos de edifício; pavimentos; área construída	ODbL (portal)	Atualização irregular; cobertura por bairro a medir (E4)	Pronto para uso
Dados Abertos Recife: Defesa Civil	Ocorrências e vistorias por localização e data	Portal CKAN (citado no manifesto 8.3)	Comportamento de quem reporta; escala de rua	Pronto para uso
SGB/CPRM RIGeo: setorização de risco	Polígonos de risco alto/muito alto	Repositório público (exemplo PE)	Data da setorização; verificar existência e	A auditar

Fonte	Uso	Licença / acesso	Limitação conhecida	Status
			versão para Recife	
IBGE CNEFE 2022	Coordenadas por endereço; espécies de endereço por edifício	Público (IBGE)	Coordenadas de apartamentos podem ser herdadas do número (IBGE)	Pronto para uso
OpenStreetMap	Rede de pedestres, edifícios, POIs	ODbL; via openrouteservice self-hosted ou OSMnx	Cobertura de calçadas e nomes de edifício variável em Recife	A medir (E4
Elevação (SRTM/Copernicus DEM ou dados municipais)	Declividade de rotas	Público	Resolução 30 m insuficiente para garagem; adequada para rota	Pronto
Shadowmap API (Sunscore)	Exposição solar do edifício	Comercial (shadowmap.org/api)	Qualidade do 3D em Recife a verificar; sem planta interna	A testar; alternativa própria com alturas cadastrada
Documentos do usuário	Leitor documental	Consentimento; cifrado; retenção; sem treino	Erro de extração; exige citação e revisão	Pronto para experiment (E3)
CNM/ONR (quando o usuário informa matrícula)	Validade e situação da matrícula; chave canônica documental	Consulta pública (CNJ); pelo SAEC qualquer pessoa pode visualizar a matrícula online (documento informativo, custo de um terço da certidão digital) ou pedir certidão de qualquer cartório do país	Sem busca por endereço; pago por consulta; passo iniciado e custeado pelo usuário, só faz sentido em compra	Integração simples (deep link + upload do PDF obtido

Fonte	Uso	Licença / acesso	Limitação conhecida	Status
		(Safra/O Especialista; Provimento 127, IRIB)		
Overture Maps, tema Buildings	Fallback de pegada de edifício onde o cadastro municipal falhar; identificador global (GERS) para anexar evidências ao edifício	Aberto; conflaciona OSM, Microsoft e Google Open Buildings, este com ampla cobertura na América Latina e scores de confiança (Overture)	Pegadas derivadas de satélite podem fundir prédios vizinhos; sem nome nem endereço na maioria dos registros	Pronto para uso como fallback

7.2 Fontes excluídas da V1 e por quê

- Snapshots longitudinais de portais (risco G2 do diagnóstico).
- Sentinel-2 / Landsat para conforto térmico: sem rótulo e sem escala de unidade.
- Strava Metro, Waze, tráfego comercial: acesso condicionado e proxies frágeis.
- Google Maps Platform para geocodificação e lugares: restrições de cache (8.7 do manifesto) conflitam com o ledger persistente; usar OSM e dados municipais.

7.3 Tecnologias e métodos alternativos considerados

Necessidade	Opção A (escolhida)	Opção B	Por que A
Resolução de edifício	Splink sobre campos estruturados + confirmação humana	Embeddings multimodais de fachada	A é explicável, barata e gera rótulos; B exige base de fotos de fachada que não existe
Isócronas e declividade	openrouteservice self-hosted / OSMnx	Google Routes	Sem restrições de cache; custo zero por consulta
Exposição solar	API externa com 3D	Cálculo próprio com alturas cadastradas	A é mais rápida para validar valor; B entra se o 3D externo for ruim em Recife

Necessidade	Opção A (escolhida)	Opção B	Por que A
Leitura de documentos	LLM com parsing e citação obrigatória de página	Classificador treinado	Sem corpus rotulado; A permite verificação pelo usuário
Geração de texto dos cartões	Templates por categoria	LLM livre	Controle de wording; auditabilidade; testes automatizados
Preço	Apenas regras de consistência e custo total	Modelo hedônico	Sem rótulo de transação; incumbentes dominam (QPreço, DataZap); precisão de AVM depende do preço pedido como feature (Zestimate: ~1,8% on-market vs ~7% off-market, Naperville.com)

7.4 Dependências e falhas de fonte

- Cada fonte tem contrato (esquema, data, cobertura, comportamento se indisponível). Se uma fonte falha, o cartão correspondente vira "Desconhecido: não conseguimos consultar [fonte] agora", nunca ausência silenciosa.
- Dependência mais frágil: extração da página do portal (mudanças de layout, bloqueio). Mitigação: fallback para "cole o texto do anúncio" e entrada por endereço.

---

8. Inteligência de decisão

Priorização dos cartões (ordem dentro de cada bloco):

1. Registros oficiais com escala igual ou menor que o lote (maior especificidade primeiro).
2. Inconsistências entre declarado e cadastrado.
3. Observações diretas geométricas (rotas, sol) com desvio relevante em relação ao esperado (ex.: razão rede/euclidiana > 1,5; subida > 15 m) **[HIPÓTESE sobre limiares; E7]**.
4. Registros oficiais de escala maior (rua, microárea).
5. Sinais exploratórios: não aparecem na camada 1 na V1.

Contextualização: cada cartão informa escala e data. Um registro de setor de risco a 300 m aparece como "na microárea", nunca como "no edifício".

Personalização (pós-valor): apenas (a) restrições duras declaradas, que promovem cartões a "Incompatibilidade" (ex.: sem elevador e usuário pediu acessibilidade); (b) pontos de rotina, que acrescentam rotas reais. Sem função de utilidade, sem ranking, sem inferência de preferências na V1 (adia 10.6 e 5.4 do manifesto).

Verificação: todo cartão tem botão "ver fonte" (link e trecho) e "isso está errado" (abre contestação que entra em fila de revisão e, quando confirmada, corrige o ledger e a tabela de resolução).

Conversão em ação: a matriz de perguntas (seção 3.3) mapeia cada desconhecido para uma de quatro ações. Exemplo de matriz mínima para aluguel de apartamento em Recife:

Pergunta	Evidência que responde	Ação se desconhecida
O edifício está em setor de risco oficial?	SGB/Defesa Civil × lote	Registro oficial ausente ≠ segurança; "verifique com a Defesa Civil"
A rua alaga?	Ocorrências Defesa Civil (raio, 24 meses)	Perguntar a moradores; olhar garagem após chuva
Quanto custa morar aqui por mês?	Aluguel + condomínio + IPTU + seguro	Pedir ao corretor o valor do IPTU e do seguro
A área anunciada é privativa?	Cadastro × declarado	Pedir matrícula ou convenção
O condomínio tem cota extra ou obra aprovada?	Atas (documento)	Pedir últimas 12 atas
Há inadimplência relevante?	Balancete (documento)	Pedir balancete
Há histórico de interdição ou problema estrutural documentado?	Registros oficiais; atas	Requer profissional se houver qualquer indício
Quanto sol a unidade recebe?	Sunscore do edifício + andar + orientação (parcial)	Visitar no horário crítico; perguntar orientação
Como é o acesso a pé ao transporte?	Rede + declividade	Nenhuma: respondida por geometria

---

9. Confiança e tratamento de falhas

Situação	Comportamento
Edifício não resolvido (confiança baixa)	Dossiê em "modo rua": só cartões com escala ≥ rua; bloco 1 diz explicitamente "não conseguimos identificar o prédio; informe o nome ou o número para mais detalhes"
Duas fontes conflitam (ex.: cadastro diz 10 pavimentos, anúncio diz 14º andar)	Cartão "Inconsistência" com ambas as fontes, datas, e ação (confirmar com corretor); nunca escolher silenciosamente
Fonte oficial sem registro	Cartão "Registro oficial: nenhuma ocorrência encontrada em [fonte] para [escala] em [período]. Ausência de registro não significa ausência de problema." (coerente com 24 do manifesto, "Baixa cobertura municipal")
Fonte indisponível	Cartão "Desconhecido" com motivo técnico; dossiê marcado como parcial; reprocessamento ofertado
Extração do anúncio falha ou campo implausível	Campo marcado para confirmação do usuário; análise continua com o que há
Leitor documental com baixa confiança num trecho	Trecho exibido com "confiança limitada; leia a página N"; nunca omitido
Usuário contesta um cartão	Entra na fila de revisão; ledger guarda versão anterior e correção
Qualquer indício estrutural, jurídico ou registral	Cartão "Precisa de especialista" com encaminhamento; sem diagnóstico

Regras de texto: nenhuma frase da lista 11.3 do manifesto pode ser gerada (teste automatizado); nenhum número de risco; nenhum adjetivo avaliativo sobre bairro ("seguro", "perigoso"); "não sabemos" é saída válida e contada como métrica (23.2).

---

10. Especificação do MVP

Nome: PropSight Check v1, Recife, apartamentos, aluguel e compra.

Usuário-alvo: pessoa que já tem um anúncio específico e está a até duas semanas de uma visita ou proposta.

Entrada: URL de anúncio (ZAP, Viva Real, OLX, QuintoAndar, Imovelweb, sites de imobiliárias locais) ou endereço digitado. Confirmação de edifício quando necessária.

Documentos opcionais em sessão posterior.

Capacidades essenciais (8):

1. Extração estruturada do anúncio com marcação "declarado pelo anunciante".
2. Resolução de edifício com três faixas de confiança e confirmação humana.
3. Cartões de registro oficial: setorização de risco SGB, ocorrências de Defesa Civil, edificação e lote cadastrados.
4. Cartões de consistência: área declarada vs. cadastro, custo mensal total, campos ausentes.
5. Cartões de geometria: distância de rede, declividade e travessias para 5 POIs padrão (transporte, mercado, farmácia, escola, parque) e para até 3 pontos de rotina do usuário; exposição solar do edifício.
6. Matriz de perguntas com desconhecidos e ações geradas.
7. Leitor documental referenciado (atas, balancetes, convenção).
8. Ledger de evidência exportável e dossiê compartilhável.

Explicitamente excluído: busca, comparação entre imóveis, ranking, score, estimativa de preço ou "valor justo", histórico de preço, duplicatas entre portais, conforto térmico, ruído modelado, risco de alagamento modelado, inspeção visual, áudio, LiDAR, relatos de moradores, preferências inferidas, chat livre, agente que contata terceiros, qualquer cidade além de Recife.

Menor implementação crível: um serviço web mobile-first (coerente com 20.7) com backend Python/FastAPI, PostGIS com as camadas de Recife carregadas, openrouteservice local, Splink para resolução, um LLM para extração e leitura documental, templates de cartão e suíte de testes de wording. Equipe: 3 pessoas por 10 a 12 semanas após E1 e E4 **[HIPÓTESE]**.

O problema técnico mais difícil e como testá-lo antes de construir: resolução de edifício (E1). Protocolo: 200 anúncios reais rotulados; pipeline só de dados (sem UI); relatório de top-1/top-3/falsos positivos por bairro e por anunciante. Resultado decide a UI: se top-1 em confiança alta ≥ 70%, o fluxo "cole a URL" é o principal; se < 50%, a entrada principal passa a ser endereço + mapa e a URL vira atalho.

---

11. Plano de validação

Dois eixos: qualidade técnica e valor para o usuário. Limiares são hipóteses iniciais; cada experimento tem decisão associada.

11.1 Qualidade técnica

Indicador	Como medir	Limiar inicial (hipótese)	Decisão se abaixo
Precisão de extração por campo (preço, área, condomínio, IPTU, andar, edifício, rua)	200 anúncios rotulados (E8)	Erro < 5% nos campos monetários e de área; taxa de endereço completo reportada	Confirmação obrigatória de campos críticos
Resolução de edifício	E1	Top-1 alta ≥ 70%; top-3 ≥ 90%; falso match alta < 2%	Entrada por endereço como principal
Cobertura de fontes por bairro	E4	Edificações ≥ 80% nos 10 bairros com mais anúncios	Restringir bairros ou cidade
Claims sem fonte rastreável	Auditoria de 50 dossiês	0%	Bloquear cartão sem fonte
Claims falsos ou com wording proibido	Auditoria de 50 dossiês por dois revisores + testes automáticos	0	Correção de template; incidente registrado
Leitor documental	E3: 30 conjuntos rotulados	Recall de eventos ≥ 80%; citação de página correta ≥ 95%; status correto ≥ 85%	Reduzir a localizador de trechos
Taxa de "desconhecido" por pergunta	Contagem no ledger	Reportada por pergunta; sem limiar (é informação, não falha)	Priorizar fonte que mais reduz desconhecidos
Tempo até camada 1	Instrumentação	Mediana < 60 s; p90 < 120 s	Otimizar paralelismo; pré-carregar camadas
Correções manuais por dossiê	Toques em "corrigir" e "isso está errado"	< 1 por dossiê	Investigar campo ou fonte com mais correções

11.2 Valor para o usuário

Indicador	Como medir	Limiar inicial (hipótese)	Decisão se abaixo
Descoberta nova e relevante	E2: pós-sessão, "algo que você não sabia e que muda uma pergunta, visita ou proposta?"	≥ 50% das sessões	Reavaliar quais fontes geram descoberta; possivelmente mudar recorte
Superioridade sobre ChatGPT e pesquisa manual	E2: rubrica cega	0 claims falsos (vs. qualquer número no ChatGPT); ≥ 2 descobertas verificáveis a mais	Sem diferencial: parar e voltar à pesquisa de dores
Compreensão	E2/E6: usuário explica com as próprias palavras por que um cartão apareceu	≥ 8 de 10	Simplificar templates
Confiança com desconhecidos	E5 A/B	≥ 20% maior intenção de pedir documento/visitar; sem aumento de abandono	Desconhecidos só na camada 2
Conclusão do fluxo	Instrumentação	≥ 80% das URLs coladas chegam à camada 1	Diagnosticar passo de confirmação
Retorno com documentos	Instrumentação	≥ 25% dos dossiês recebem documentos em 14 dias	Melhorar pedido de documentos; testar canal corretor
Compartilhamento	Instrumentação	≥ 30% dos dossiês compartilhados	Rever formato exportado
Disposição a pagar e canal corretor	E6	≥ 20% pagariam; ≥ 3 corretores usariam recorrentemente	Reposicionar para B2B2C

11.3 Sequência e portões

1. Semanas 1 a 3: E4 e E1 (dados, sem UI). Portão: resolução e cobertura.
2. Semanas 3 a 6: E2 com dossiês concierge (manuais, usando o pipeline de dados) e E6. Portão: descoberta e diferencial vs. ChatGPT.
3. Semanas 6 a 9: E3 e E8 em paralelo com o protótipo navegável; E5.
4. Semanas 9 a 20: construção do MVP; instrumentação das métricas de 11.1 e 11.2.
5. Após 50 dossiês reais: auditoria de claims; decisão sobre V1.1.

---

12. Roteiro de evolução

Cada etapa só se justifica pela evidência da anterior, nunca por calendário.

Etapa	Capacidade adicionada	Pré-condição (evidência)	Dependência técnica
V1 (MVP)	Os 8 itens da seção 10	E1, E2, E4 aprovados	Ledger, resolvedor, fontes oficiais
V1.1	Documentos: matrícula via CNM; convenção; regimento; detecção de cláusulas restritivas (pets, locação curta)	Retorno com documentos ≥ 25%	Leitor documental validado (E3)
V1.2	Canal corretor: dossiê white-label, lote de URLs, assinatura	E6 indica demanda; modelo Sprift	Autenticação e multi-usuário
V2	Comparação lado a lado de 2 a 4 dossiês do mesmo usuário; restrições duras como filtro	≥ 30% dos usuários com 2+ dossiês	Ledger comparável por campo (6.6 do manifesto, "Comparação de alternativas")
V2.1	Histórico de preço e duplicatas	Fonte lícita de anúncios (licença, parceria ou base própria de dossiês)	Splink já em uso; modo batch
V2.2	Feedback pós-visita e pós-mudança como primeiro ground truth (o que se confirmou, o que surpreendeu)	Retenção suficiente para amostra ≥ 100	Formulário curto; consentimento

Etapa	Capacidade adicionada	Pré-condição (evidência)	Dependência técnica
V3 (pesquisa → produto)	Primeiro sinal composto validado (candidato: acesso em chuva, cruzando ocorrências, topografia e feedback de V2.2)	Validação independente ≥ 100 observações; FP < 20%	Hidden Signals Engine como programa de pesquisa a partir de V2.2
V3.1	Checklist de visita com captura de fotos organizada (sem diagnóstico)	Usuários pedem; custo de armazenamento controlado	Sem visão computacional avaliativa
V4	Segunda cidade	Catálogo de fontes auditado para a nova cidade (15.3 do manifesto)	Resolvedor parametrizável por município
Horizonte	Building Memory governado; relatos; API de evidências (27.E, 27.I)	Base de usuários, política jurídica, moderação	Não planejar antes de V3

---

13. Questões em aberto e trade-offs

O que ainda não se sabe e mudaria esta proposta:

1. **Taxa real de resolução de edifício em Recife (E1).** Abaixo de 50% em confiança alta, a entrada por URL deixa de ser o eixo e o produto se aproxima de Sprift (endereço primeiro).
2. **Se as fontes oficiais geram descobertas frequentes (E2, E7).** Se registros de risco e geometria raramente produzem algo novo nos bairros onde há anúncios, o núcleo se desloca para o leitor documental, e o produto vira "due diligence condominial" primeiro.
3. **Licitude da leitura única da página do anúncio a pedido do usuário.** Parecer jurídico pendente; se negativo, entrada por endereço e por texto colado.
4. **Economia (E6).** B2C puro pode não sustentar; o canal corretor (V1.2) pode precisar vir antes.
5. **Qualidade do 3D de Recife na Shadowmap** para exposição solar; se ruim, calcular com alturas cadastradas.

6. **Existência e licitude de uso de lista nominal de edifícios interditados ou em acordo (prédios-caixão).** Se existir e for pública por endereço, é o cartão de maior impacto possível; se não, o tema fica em "registros oficiais ausentes" com encaminhamento.

Trade-offs assumidos:

- **Profundidade em uma cidade vs. abrangência.** Escolhida a profundidade; a tabela de resolução de edifícios é o ativo que só se constrói localmente.
- **Nenhum score vs. simplicidade de comunicação.** Escolhido nenhum score, aceitando que o produto é menos "vendável" em uma tela; o precedente Zillow/First Street sustenta a escolha.
- **Sem scraping longitudinal vs. inteligência de mercado.** Escolhido sem; aceita-se não ter histórico de preço na V1.
- **Templates vs. LLM livre nos cartões.** Escolhidos templates; aceita-se texto menos fluido em troca de auditabilidade.
- **Confirmação humana do edifício vs. automação total.** Escolhida a confirmação; aceita-se um toque a mais em troca de zero falso match em confiança alta e de rótulos gratuitos.

Decisões que devem ser validadas antes de qualquer desenvolvimento adicional: E1 e E4 (viabilidade), depois E2 e E6 (valor e negócio). Nada além do pipeline de dados deve ser construído antes desses quatro resultados.

Apêndice. Como e por que esta proposta difere do manifesto

Tema	Manifesto (seção)	Esta proposta	Evidência ou razão
Caso de uso inicial	Não escolhido (29, 30)	Verificação de um anúncio em Recife, apartamentos	Única decisão que não exige inventário nem scraping; seção 28 aplicada à 6
Módulo central	Seis módulos (4)	Resolvedor de edifício + ledger + desconhecidos + leitor documental	Maturidade alcançável em um trimestre (diagnóstico, seção 9)

Tema	Manifesto (seção)	Esta proposta	Evidência ou razão
Hidden Signals Engine	Componente do produto (4.2)	Programa de pesquisa a partir de V2.2	Sem ground truth antes de feedback de usuários (G3)
Market Intelligence	Módulo (4.5)	Apenas consistência e custo total	Incumbentes (QPreço, DataZap, FipeZap); AVMs dependem do preço pedido; fonte longitudinal ilícita ou frágil (G2)
Visit Companion	Módulo com áudio, LiDAR, fotos (4.4, 13)	Checklist textual gerado dos desconhecidos; fotos só em V3.1 sem diagnóstico	Hardware, rótulos e risco de falso alarme
Building Memory	Módulo (4.6)	Horizonte pós-V3	Governança (12.4) desproporcional ao estágio
Personalização	Escolhas pareadas, utilidade U(p|u,c) (5.4, 10.6)	Restrições duras e pontos de rotina, só após o primeiro resultado	Manifesto admite não saber se funciona (17.4); fricção antes do valor
Entrada	Cinco possibilidades (5.3)	URL com confirmação de edifício; endereço como alternativa	Jornada desenhada (seção 4); E1 decide
Arquitetura	Pipeline batch com snapshots (9.1)	Sob demanda; batch condicional a fonte lícita	Modo on-demand não depende do batch; o inverso sim
Roteiro	A → H por módulo (21)	E4, E1 → E2, E6 → MVP → evidência-dependente	Fase D (experiência) antes de B e C (dados e sinais)
Fontes	Defesa Civil, OSM, Sentinel-2, ZAP (8)	+ lotes/edificações Recife, CNEFE, SGB, CNM, Shadowmap, openrouteservice; −	Catálogo verificado (diagnóstico, seção 6)

Tema	Manifesto (seção)	Esta proposta	Evidência ou razão
		Sentinel-2, ZAP longitudinal	
Escala de confiança	Seis categorias (11)	Sete: adiciona "declarado pelo anunciante"	É a categoria mais frequente no primeiro uso
Diferencial	Seis candidatos (7)	Dois imediatos: identidade resolvida com proveniência; desconhecidos como saída	Os demais são cumulativos e inacessíveis na V1
Riscos	Treze (24)	+ substituição por LLM genérico; + economia B2C; + dependência de extração da página	Benchmark (Homie, uso de ChatGPT por compradores, Sprift B2B2C)